

SK네트웍스 Family AI과정 6기

모델링 및 평가 LLM 활용 소프트웨어

□ 개요

- 산출물 단계 : 모델링 및 평가
- 평가 산출물 : LLM 활용 소프트웨어
- 제출 일자 : 2025.03.09
- 깃허브 경로 : <https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN06-FINAL-3Team>
- 작성 팀원 : 장예린

개요	이 시스템은 화장품 회사(아모레퍼시픽)의 내부분서 정보 검색 및 제품 정보 제공을 위해 구축되었습니다. NLP 기반의 검색 엔진을 활용하여 한글과 영문 검색을 지원하고, 빠르고 정확한 검색 기능을 제공합니다. 시스템의 주요 기능은 화장품 성분, 제품 등을 검색하고 분석하여 관련 정보를 효율적으로 제공하며, 자사의 재무 및 회계 정보까지 조회할 수 있습니다.
데이터 전처리	1. 제품데이터 • 자사(아모레퍼시픽) 제품 군 크롤링 ◦ 자사의 모든 브랜드들의 판매제품 데이터 수집 ■ 제품정보(이름, 가격, 성분, ...등) 및 제품이미지 크롤링 ■ 제품별 카테고리1(대분류), 카테고리2(소분류) 부여 ■ 각 카테고리별 키워드를 통한 분류 • 타사 제품군 크롤링 ◦ 올리브영의 카테고리별 화장품 데이터(제품정보 및 이미지) 수집 ◦ 상이한 카테고리 정리 및 제품군 정리 ◦ ERD 테이블에 맞춘 전 제품데이터 컬럼 정리 ◦ 띄어쓰기 및 공백 제거, 묶음/기획 상품 제거 2. 브랜드 데이터 • 아모레퍼시픽 공식사이트 내 브랜드 스토리, 방향성, 가치 등등의 contents 크롤링 ◦ 불용어 및 필요없는 항목 전처리

	3. 내부문서 데이터 - 아모레퍼시픽 공식사이트 내 자료를 pdfplumber를 활용하여 pdf내 텍스트와 표 추출 - 불필요한 텍스트 제거 및 정리 - 표 데이터 필터링 및 정제 4. 저널 데이터 - Allure Korea의 저널 데이터 크롤링 - pdfplumber를 활용해 뉴스 및 저널 데이터를 PDF에서 추출 - ERD 테이블 구조(title, date, author, link, content)에 맞춰 데이터 정리 - 불필요한 정보(날짜 패턴, 특정 키워드, 중복 문구 등) 정제 후 JSON 저장 5. 뉴스 데이터 - cosin 사이트 내 기사 데이터 크롤링 - ERD 테이블 구조(title, date, author, link, content)에 맞춰 JSON 저장 6. 성분데이터 - 식약처의 OPEN API(화장품 원료성분정보)의 표준명 + 영어명 + 이명을 기반으로 JOIN - 원료성분정보 데이터에 아모레홈페이지 내 성분데이터의 설명과 ecogolik의 용도, 주의사항을 결합하여 성분 데이터를 도출 - 각 성분별로 하나의 txt 파일로 저장하여 사내문서화
기대효과	- 화장품 성분, 제품 등을 검색하고 분석하여 관련 정보를 효율적으로 제공 - 사내 재무 및 회계 등 회사에 관한 정보를 검색하고 관련 정보를 효율적으로 제공 - 문서 및 뉴스 즐겨찾기 기능 제공
도구 및 환경	- Frontend: Nuxt.js - Backend: FastAPI - LLM Model: llama-3.2-1b - Embedding Model: multilingual-e5-large - 배포: RunPod - 프로그래밍 언어: Python - DataBase: maria DB, Chroma DB - 저장소: AWS S3
결론	주요 성과

- | | |
|--|---|
| | <ul style="list-style-type: none">○ 일반적인 데이터를 Maria DB에 저장○ LLM 을 활용하여 question - context 데이터셋 생성○ question - context 데이터셋을 임베딩하여 벡터 데이터 생성○ 벡터 데이터를 Chroma DB 에 저장○ Nust.js로 웹 개발
● 향후 계획<ul style="list-style-type: none">○ 뉴스를 일주일 간격으로 크롤링하여 주마다 업데이트 하도록 개발 예정○ 용어사전을 활용하여 비전문가들에게 문서 및 제품과 더불어 용어 및 성분에 대한 도메인 제공 |
|--|---|