

SK네트웍스 Family AI과정 3기

모델배포 시스템 구성도

□ 개요

- 산출물 단계 : 모델배포
- 평가 산출물 : 시스템 구성도
- 제출 일자 : 2025.03.14
- 깃허브 경로 : <https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN06-FINAL-3Team>
- 작성 팀원 : 장예린

개요	이 시스템은 AWS 클라우드 기반으로 동작하며, SLLM을 활용한 질문 기반 문서 검색 시스템입니다. 사용자가 입력한 질문에 맞는 문서를 찾아 제공하며, 이를 지원하기 위해 Nuxt.js 기반 웹 인터페이스, MariaDB/ ChromaDB/ S3로 데이터 관리, GitHub을 통한 코드 관리, EC2 인스턴스에서 애플리케이션 실행이 통합된 구조를 갖추고 있습니다. 이 외에 내부분서 및 뉴스, 외부 뉴스, 제품 데이터 등을 제공합니다.
구성 요소	1. GitHub & GitHub Actions: • GitHub는 소스 코드를 관리하는 저장소로 보이며, GitHub Actions는 CI/CD(지속적 통합/지속적 배포) 파이프라인을 실행하는 데 사용됩니다. • 사용자가 코드를 푸시하면 GitHub Actions가 이를 감지하고 자동으로 빌드, 테스트, 배포 작업을 수행하는 흐름으로 보입니다. 2. AWS (Amazon Web Services): 이 시스템은 AWS 클라우드 환경에서 동작합니다. 2-1. EC2 인스턴스: EC2(Elastic Compute Cloud)는 AWS의 가상 서버로 두 개의 EC2 인스턴스를 사용합니다. 1) 웹애플리케이션용 서버 (Nuxt.js, FastApi, MariaDB) ◦ Nginx: 웹 서버로, 클라이언트 요청을 처리하고 애플리케이션으로 라우팅하는 역할을 합니다. ◦ Nuxt.js: 프론트엔드 프레임워크로, 사용자 인터페이스를 제공하는 역할을 합니다. Nuxt.js 애플리케이션이 Nginx 뒤에서 동작하며, 정적/동적 콘텐츠를 제공합니다.

	○ FastAPI: 백엔드 API 서버로, 비즈니스 로직을 처리하고 데이터를 제공합니다. Python 기반의 FastAPI가 사용되고 있네요. ○ Unicorn: FastAPI와 함께 사용되는 ASGI 서버로, Python 애플리케이션을 실행하는 데 사용됩니다. ○ MariaDB: 데이터베이스로, 애플리케이션 데이터를 저장합니다. FastAPI가 MariaDB와 통신하여 데이터를 읽고 쓰는 구조입니다. 2) Vector Store용: ChromaDB ○ ChromaDB는 벡터 데이터베이스로, 주로 AI/ML 워크로드에서 임베딩(embedding) 데이터를 저장하고 검색하는 데 사용됩니다. 2-2. S3: ● AWS S3(Simple Storage Service)는 객체 스토리지로, 정적 파일(예: 이미지, CSS, JS 파일 등)을 저장하는 데 사용됩니다. ● Nuxt.js와 FastAPI가 S3와 통신하여 필요한 파일을 가져옵니다. 3. sLLM (Small Language Model): ● Runpod 서버에 모델을 설치합니다. ● sLLM은 소형 언어 모델로, ChromaDB와 연결되어 벡터 데이터를 활용해 추론(inference)을 수행하는 구조입니다. ● FastAPI가 sLLM과 통신하여 임베딩 등 여러 기능을 제공합니다.
데이터 흐름	1. 사용자가 GitHub에 코드를 푸시하면 GitHub Actions가 CI/CD 파이프라인을 실행하여 애플리케이션을 빌드하고 AWS EC2에 배포합니다. 2. EC2 인스턴스에서 Nginx가 사용자 요청을 받아 Nuxt.js(프론트엔드) 또는 FastAPI(백엔드)로 라우팅합니다. 3. FastAPI는 MariaDB에서 데이터를 가져오거나 S3에서 정적 파일을 제공하며, 필요 시 sLLM과 ChromaDB를 활용해 AI 기능을 수행합니다. 4. sLLM은 ChromaDB에 저장된 벡터 데이터를 활용해 추론을 수행하고 결과를 FastAPI로 반환합니다. 5. 최종적으로 사용자는 Nuxt.js를 통해 결과를 확인합니다.