

SK네트웍스 Family AI과정 6기

데이터 전처리 인공지능 학습 결과서

□ 개요

- 산출물 단계 : 데이터 전처리
- 평가 산출물 : 인공지능 학습 결과서
- 제출 일자 : 2025.03.09
- 깃허브 경로 : <https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN06-FINAL-3Team>
- 작성 팀원 : 장예린

실험 개요

성능 평가 실험

이 실험에서는 임베딩 모델 선정을 위해 각 모델로 임베딩 후 hit rate 측정한다.

1. 임베딩 모델 선정

- 한글 텍스트 임베딩 모델 리더보드 (https://github.com/su-park/mteb_ko_leaderboard) 상위 10개의 모델 중 Memory Usage가 5GB 이하 모델 중 Retrieval과 Ranking 성능의 평균점수가 높은 두 모델을 선정

no.	Model	Memory Usage (GB)	Embedding Dimensions	Max Tokens	Source
1	SFR-Embedding-2_R	26.49	4096	32768	Salesforce/SFR-Embedding-2_R
2	gte-Qwen2-7B-instruct	28.36	3584	131072	Alibaba-NLP/gte-Qwen2-7B-instruct
3	bge-multilingual-gemma2	34.43	3584	8192	BAAI/bge-multilingual-gemma2
4	e5-mistral-7b-instruct	26.49	4096	32768	intfloat/e5-mistral-7b-instruct
5	jina-embeddings-v3	2.13	1024	8192	jinaai/jina-embeddings-v3
6	LM2Vec-Meta-Llama-3-supervised	27.96	4096	8192	McGill-NLP/LM2Vec-Meta-Llama-3-8B-Instruct-mntp-supervised
7	multilingual-e5-large-instruct	2.89	1024	514	intfloat/multilingual-e5-large-instruct
8	multilingual-e5-large	2.89	1024	514	intfloat/multilingual-e5-large
9	bge-m3	2.11	1024	8192	BAAI/bge-m3
10	ko-sroberta-multitask	1.84	768	512	jhgan/ko-sroberta-multitask

2. 임베딩 모델 구축

- ChromaDB를 이용하여 문서데이터(.txt, .md, json)을 임베딩하고 저장
- 임베딩후 benchmark data에 대한 Hit Ratio 측정

평가 및 점수

● 각각 생성된 질문(k) 1개, 3개, 5개와 비교하여 Hit Rate 측정

● 실험은 RunPod GPU (A40)에서 진행

3.. 최종 모델 선정

● 총 2가지 모델 중 검색 성능이 가장 우수한 모델을 최종 선정

● 최종 선정된 모델을 운영 환경에 적용

● 임베딩 평균점수 계산

● bge-m3(66.135) 와 multilingual-e5-large(64.17) 선정

Model	Retrieval	Ranking	점수
jina-embeddings-v3	42.95	74.98	58.965
multilingual-e5-instruct	52.68	74.52	63.69
multilingual-e5-large	54.87	73.47	64.17
bge-m3	59.98	72.29	66.135
ko-sroberta-multitask	48.33	60.98	54.655

● Hit Ratio 측정

○ bge-m3

비교 질문 개수 (k)	hit rate
1	0.56
3	0.63
5	0.65

○ multilingual-e5-large

비교 질문 개수 (k)	hit rate
1	0.73
3	0.83
5	0.85