

SK네트웍스 Family AI과정 6기

데이터 전처리 자체 LLM 인공지능

□ 개요

- 산출물 단계 : 데이터 전처리
- 평가 산출물 : 자체 LLM 인공지능
- 제출 일자 : 2025.03.09
- 깃허브 경로 : <https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN06-FINAL-3Team>
- 작성 팀원 : 장예린

개요	- 임베딩 모델에 HyQE 적용을 위해 각 문서에 따른 자연어 질문을 생성하는 LLM 모델을 개발.
학습	학습 데이터 소스 • https://www.aihub.or.kr/aihubdata/data/view.do?currMenu=115&topMenu=100&aihubDataSe=realm&dataSetSn=89 • https://huggingface.co/datasets/yuneun92/create_ga_news 학습 환경 • 사용 모델 : llama-3.2-1b • 학습 환경: RunPod GPU(A100 PCIe) • 학습 데이터셋 : input(context) - output (question) input "아래 instruction에 따라 주어진 context에서 질문을 생성하세요. Context: 원웅중(36강원도청)이 조종간을 잡은 한국 탑승레이 남자 4인승 대표팀이 세계선수권대회 10위권에 3년 연속 입성하면서 2021 베이징 올림픽 메달에 대한 기대를 높이고 있다. 원웅중-김진수-이영민-정현우 팀은 15일(한국시간) 독일 뮌헨베르크에서 끝난 2020-2021 국제봅슬레이스피드스케이팅경기(89) 세계선수권 남자 탑승레이 4인승 경기에서 1~4차 시기 합계 3분37.55초를 기록해 9위에 올랐다. 전날 끝난 12차 시기에서 합계 1분49.54초를 기록해 8위에 자리했던 원웅중 팀은 34차 시기에서 1분40.55초로 더 좋은 기록을 남기지만, 한 계단 낮은 9위로 대회를 마무리했다. 이번 경기로 원웅중 팀은 3년 연속 10위권 안에 진출했다. 앞서 2018-2019시즌 대회에서는 7위, 2019-2020시즌 대회에서는 8위에 오른 바 있다. 한국 탑승레이의 기록으로 볼리던 원웅중은 지난 2018 평창 동계올림픽에서 서양우와 함께 남자 2인승 탑승레이 경기에서 6위(3분17.54초)로 대회를 마친 바 있다. 사상 처음으로 스타레온 관매달을 따냈던 윤성빈과 더불어 메달에 대한 기대가 높았던 부문이어서 아쉬움이 남았다. 1차 시기에서의 치명적인 주행 실수가 재인이었다. 원웅중은 아쉽게 해설 독에 실락했지만, 한국 탑승레이의 사상 첫 올림픽 팀 10위 진입으로 새로운 이정표를 세울 수 있었다. 탑승레이는 지난 2010년 대회고 4년간 대 주승 탑승레이에 입문해 아스팔트 결빙 언덕과 벼랑 달린 중고 경계 하나로 치열한 경쟁을 펼쳐왔던 것인데 비교적 불확실했던 상황이다. 이번 대회에서 대표팀의 석영진(강원도청)-이인우-채병도-김동현 팀은 1~4차 시기 합계 3분40초11로 18위에 올랐다. 여자 모노스케이팅 탑승레이에서는 김유란(강원도청)이 1~4차 시기 합계 4분4.504로 14위에 자리했다. Instruction: 위 context에서 5개의 질문을 생성하세요. output "한국 탑승레이 남자 4인승 대표팀이 세계선수권대회에서 어떤 성과를 거두었나요? 원웅중-김진수-이영민-정현우 팀의 1~4차 시기 합계 기록은 어떻게 되나요? 원웅중 팀은 전날 끝난 12차 시기에서 어떤 기록을 세웠나요? 원웅중 팀의 대회 최우의 순위는 어디인가요? 원웅중이 평창 동계올림픽에서 남자 2인승 탑승레이 경기에서 달렸던 순위와 기록은 무엇인가요?" 1 input "아래 instruction에 따라 주어진 context에서 질문을 생성하세요. Context: 중학교 시절 학교 폭력 논란의 당사자인 여자 프로배구 한국생명의 '황동미'가 '이재영-이다영(25)의 국가대표 자격이 무기한 박탈됐다. 대한민배구협회 관계자는 15일 연합뉴스 통화에서 '아마추어 배구를 관장하는 한회로서 무기는 책임감을 느꼈다'며 '이재영과 이다영을 향후 국가대표 선수 선발 대상에서 무기한 제외하기로 결론 내렸다'고 밝혔다. 배구협회는 전날 실수 회피에 이어 이날 오전에도 회의를 개최했다. 논의 결과 협회는 국가대표 선수로서의 부적절한 행동에 대해 발발하게되는 자원에서 중징계를 결정했다. 소속 구단인 한국생명에서 이재영-이다영 지명에 무기한 출전정지 징계를 내렸다. 한국생명은 '사안이 심각한 만큼 해당 선수들에 대해 무기한 출전정지를 결정했다'며 '두 선수는 자숙 기간 중 배를 관는 반성은 물론 피해자분들을 직접 만나 용서를 비는 등 피해자분들의 상처가 조금이나마 치유될 수 있도록 모든 노력을 다해야 할 것'이라고 밝혔다. 앞서 지난 10일 온라인 커뮤니티에는 이재영-이다영 지매의 과거 학교 폭력 의혹을 폭로하는 글이 올라왔다. 현재 배구선수 목록 피해자들입니다라는 제목의 게시물은 이재영-이다영 지매가 가한 학교 폭력 의혹에 상세히 묘사했다. 논란이 커지자 이재영-이다영 지매는 지주의 인스타그램 계정에서 사과문을 올렸다. Instruction: 위 context에서 5개의 질문을 생성하세요. output "중학교 시절 학교 폭력 논란의 당사자는 누구인가요? 이재영-이다영 지매에게 무기한 출전정지를 내린 소속 구단은 어디인가요? 이재영-이다영 지매의 과거 학교 폭력 의혹을 폭로하는 글이 올라온 온라인 커뮤니티의 제목은 무엇인가요? 이재영-이다영 지매가 가한 올린 사과문은 어떤 형태로 전달되었나요? 국가대표 선수 선발 대상에서 이재영과 이다영을 무기한 제외하기로 결정한 단체는 어디인가요?" 학습 과정 • 기본 모델의 프롬프트 <pre>for text in texts: num_questions = 5 if len(text) < 300 else 7 # 텍스트 길이에 따라 질문 수 결정</pre>

```
## Context:
{text}

## Instruction:
- 위 context에서 {num_questions}개의 질문을 **한국어로만** 생성하세요.
- 모든 질문은 **반드시 한국어로 작성**하세요. **영어는 절대 사용하지 마세요.**
- **질문만 작성하고 답변은 절대 포함하지 마세요.**
- **반드시 {num_questions}개까지만 질문을 생성하세요.**
- 번호를 붙여 작성하세요. 예:
  1. 이 제품의 브랜드는 무엇인가요?
  2. 이 제품의 주요 성분은 무엇인가요?
  3. 이 제품의 사용 방법은 무엇인가요?
  4. 이 제품의 장점은 무엇인가요?
  5. 이 제품이 적합한 피부 타입은 무엇인가요?

## 질문 목록:
(반드시 {num_questions}개까지만 질문을 작성하세요. **답변은 포함하지 마세요.**)
```

question <*>-All about skin scrubbing by SEED TECH™ 피드 테크가 피부 관리 솔루션을 제공하는 브랜드에 관해서는 피부를 문제점을 해결하기 위해 스크럽이 어떻게 사용되는지, 가장 아름다운 그리드 오일과 세루믹 유제가 위해 3세대 1986 년부터 유전자 기반하여 피부 장벽의 근근적인 유효성 테스트 SEED TECH™를 제안합니다. 프리미엄 피드 크림은 단단한 용액이 좋은 피드 캠퍼드의 피부 장벽 리노-리페어 효과에 피드바오트닉스 성분 방아-지속 효과와 더불어 건강하고 아름다운 피부를 완성합니다.<*/>

questions 1. What is the difference between a moisturizer and a cream? 2. What is the difference between a serum and a lotion? 3. What is the difference between a face r4. What is the difference between a cleanser and a scrub? 5. What is the difference between a mask and a sheet mask? 6. What is the difference between a night crea m? 7. What is the difference between a night cream and a day cream? 1. Moisturizers are designed to keep your skin hydrated while creams are designed to lock in moisture designed to penetrate deep into the skin and deliver active ingredients directly to the skin's surface. Lotion is a lighter weight moisturizer that can be used all over the b e designed to remove dirt, oil, and makeup from the skin. Toner is designed to balance the pH of the skin and remove any excess oil or dirt. Cleansers are designed to clean and makeup from the skin. Scrubs are designed to exfoliate the skin and remove dead skin cells. Masks are designed to hydrate and nourish the skin. Sheet masks ar e a deeper level of hydration and nourishment than other types of masks. Night creams are designed to be applied at night and are often thicker and more moisturizing 2. Serums are designed to penetrate deep into the skin and deliver active ingredients directly to the skin's surface. Lotion is a lighter weight moisturizer that can be used Face washes are designed to remove dirt, oil, and makeup from the skin. Toner is designed to balance the pH of the skin and remove any excess oil or dirt. Cleansers are ove dirt, oil, and makeup from the skin. Scrubs are designed to exfoliate the skin and remove dead skin cells. Masks are designed to hydrate and nourish the skin. Sheet ed to provide a deeper level of hydration and nourishment than other types of masks. Night creams are designed to be applied at night and are often thicker and more day creams. 3. Face washes are designed to remove dirt, oil, and makeup from the skin. Toner is designed to balance the pH of the skin and remove any excess oil or dr eigned

context "글로벌에는 피치자-2001글리콜세테이트와, 모든 성분은 PPG-20 Diglyceryl Ether입니다. 이 성분의 CAS No는 주어진 정보 없습니다. 이 성분은 실제로 평균 2000인 폴리머 및 드를 함유하는 글리콜린의 이미지의 폴리오르보알코올리올리올입니다. 이 성분으로 주어진 정보가 없습니다. 이가 있습니다. 다. 사용 용도로 주어진 정보 없습니다. 다. 사용자만으로는 이 정보 가 없습니다. 사용 용도로 주어진 정보 없습니다."

questions 1. PPG-20 Diglyceryl Ether의 CAS No는 무엇입니까? 2. PPG-20 Diglyceryl Ether의 평균 분량은 얼마입니까? 3. PPG-20 Diglyceryl Ether의 분자 구조는 무엇입니 다. 4. PPG-20 Diglyceryl Ether의 평균 분자는 얼마입니까? 5. PPG-20 Diglyceryl Ether의 평균 분자는 얼마입니까? 6. PPG-20 Diglyceryl Ether의 평균 분자는 얼마입니 다. 7. PPG-20 Diglyceryl Ether의 평균 분자는 얼마입니까?

- 튜닝 후 학습데이터셋

	<pre> : {'input': '아래 instruction에 따라 주어진 context에서 질문을 생성하세요.\nContext: 원윤종(36-강원도청)이 조종간을 잡은 한국 봅슬레이 남자 4인승 대표팀이 세계선수권대회 10위권에 3년 연속 입성하면서 2021 베이징 올림픽 메달에 대한 기대를 높이고 있다. 원윤종-김진수-이경민-정현우 팀은 15일(한국시간) 독일 알텐베르크에서 끝난 2020-2021 국제 봅슬레이스켈레톤경기연맹(IBSF) 세계선수권 남자 봅슬레이 4인승 경기에서 1~4차 시기 합계 3분37초95를 기록해 9위에 올랐다. 전날 끝난 1~2차 시기에서 합계 1분49초40를 기록해 8위에 자리했던 원윤종 팀은 3~4차 시기에서 1분48초55로 더 좋은 기록을 냈지만 한 계단 낮은 9위로 대회를 마무리했다. 이번 경기로 원윤종 팀은 3년 연속 10위권 안에 진출했다. 앞서 2018-2019시즌 대회에서는 7위, 2019-2020시즌 대회에서는 8위에 오른 바 있다. 한국 봅슬레이의 기동으로 불리던 원윤종은 지난 2018 평창 동계올림픽에서 서영우와 함께 남자 2인승 봅슬레이 경기에서 6위(3분17초40)로 대회를 마감한 바 있다. 사상 처음으로 스켈레톤 금메달을 따냈던 윤성빈과 더불어 메달에 대한 기대가 높았던 부문이어서 아쉬움이 높았다. 1차 시기에서의 치명적인 주행 실수가 패인이었다. 원윤종은 어렵게 메달 획득에 실패했지만, 한국 봅슬레이 사상 첫 올림픽 ‘톱10’ 진입으로 새로운 이정표를 세울 수 있었다. 원윤종이 8년 전인 2010년 대학교 4학년 때 처음 봅슬레이에 입문해 아스팔트 깔린 언덕과 바퀴 달린 썰매 하나로 시작했던 것에 비교하면 괄목할 만한 성과였다. 이번 대회에서 대표팀의 석영진(강원도청)-이선우-채병도-김동현 팀은 1~4차 시기 합계 3분40초11로 18위에 올랐다. 여자 모노볼(1인승 봅슬레이)에서는 김유란(강원도청)이 1~4차 시기 합계 4분4초04로 14위에 자리했다.\n\nInstruction: 위 context에서 5개의 질문을 생성하세요.\n\nQuestions: ', 'output': '1. 한국 봅슬레이 남자 4인승 대표팀이 세계선수권대회에서 어떤 성과를 거두었나요?\n2. 원윤종-김진수-이경민-정현우 팀의 1~4차 시기 합계 기록은 어떻게 되나요?\n3. 원윤종 팀은 전날 끝난 1~2차 시기에서 어떤 기록을 세웠나요?\n4. 원윤종 팀의 대회 마무리 순위는 어디인가요?\n5. 원윤종이 평창 동계올림픽에서 남자 2인승 봅슬레이 경기에서 달성한 순위와 기록은 무엇인가요?'} </pre>																		
	학습 결과 <table> <tr> <th>Step</th><th>Training Loss</th></tr> <tr><td>25</td><td>1.124600</td></tr> <tr><td>50</td><td>0.997000</td></tr> <tr><td>75</td><td>1.007700</td></tr> <tr><td>100</td><td>0.909000</td></tr> <tr><td>125</td><td>0.916700</td></tr> <tr><td>150</td><td>0.938000</td></tr> <tr><td>175</td><td>0.891300</td></tr> <tr><td>200</td><td>0.870200</td></tr> </table>	Step	Training Loss	25	1.124600	50	0.997000	75	1.007700	100	0.909000	125	0.916700	150	0.938000	175	0.891300	200	0.870200
Step	Training Loss																		
25	1.124600																		
50	0.997000																		
75	1.007700																		
100	0.909000																		
125	0.916700																		
150	0.938000																		
175	0.891300																		
200	0.870200																		
모델 활용 결과	사내 문서에 대한 질문 생성 - context 300자 이상에 대해서 질문 5개, 7개의 질문을 생성하여 context 의 의미를 반영하는 질문 생성 context " AP (에이피 뷰티)Wn브랜드 카테고리:화장품, AP의 여정은 오랜 통념에 대한 도전에서 시작되었습니다. 우리는 아홉다음에는 한계가 없다는 믿음으로, 그동안 해결하지 못했던 피부 문제와 고민에 대해 완전히 새로운 차원의 결과를 제공하는 혁신적인 고성능 스킨케어 솔루션을 선보입니다. APEX OF SKINCARE TO UNVEIL BEAUTY BEYOND 새로운 차원의 피부 과학 기술 화장품 영역에 국한되지 않는 폭넓은 연구와 다양한 글로벌 전문 기관과의 협력을 통하여 피부 과학의 혁신을 선도합니다. 독자 특허 성분 아주 작고 정밀한 단위에서부터 연구하여 탄생시킨 순수 독자 성분들은 기존 성분의 한계를 뛰어넘는 압도적인 효능과 피부 변화를 제공합니다. 결과를 검증하는 선도적인 클리니컬 테스트 쌍둥이 대상, 특수 케어 영감 인체적용시험 등 전문 평가 기관과의 공동 연구를 통해 정밀한 선도적인 클리니컬 테스트 방식은 고성능 안티에이징 효능과 새로운 차원의 피부 결과를 검증합니다. 피부 컨설팅이론 최첨단 피부 진단 디바이스로 당신의 현재 피부 컨디션 분석과 솔루션을 제안하고, AP가 개발한 독자적인 스킨 트리트먼트 프로그램으로 새롭고 특별한 경험을 선사합니다. AP 스파 70년 이상의 피부 과학 연구의 코어를 담은 AP만의 스파 트리트먼트, AP의 고효능 제품과 고객님의 피부 고민에 따른 트리트먼트 테크닉 솔루션의 놀라운 시너지를 경험해보세요. 시그니처 기프트 포장 소중한 이에게 전하는 마음이 더욱 뜻깊고 특별한 선물로 전달될 수 있도록 AP만의 섬세한 터치로 마무리한 품격있는 포장 서비스를 제공합니다. 멤버십 클럽 빛이 나는 당신을 위한 VIP Membership. 소중한고 특별한 고객님의만을 위한 AP의 고품격 서비스와 다양한 혜택을 제공합니다.</p>" question "1. AP (에이피 뷰티) 브랜드의 여정은 무엇인가요? 2. AP (에이피 뷰티)의 여정은 오랜 통념에 대한 도전에서 시작되었나요? 3. AP (에이피 뷰티) 브랜드의 여정은 어떤 분야에 국한되지 않나요? 4. AP (에이피 뷰티) 브랜드의 여정은 어떤 연구와 다양한 글로벌 전문 기관과의 협력을 통하여 피부 과학의 혁신을 선도했나요? 5. AP (에이피 뷰티) 브랜드의 여정은 어떤 선도적인 클리니컬 테스트 방식을 사용했나요? 6. AP (에이피 뷰티) 브랜드의 여정은 어떤 피부 과학 기술을 선보였나요? 7. AP (에이피 뷰티) 브랜드의 여정은 어떤 피부 컨설팅이론 서비스를 제공했나요?" - 성분에 대한 질문 생성시 표준명을 인식하여 질문에 반영																		

	▼ 10096 context "표준명은 스테아로일메틸글루카마이드스테아레이트이고; 영문명은 Stearoyl Methylglucamide Stearate입니다; 이 성분의 CAS No는 주어진 정보가 없습니다.; 이 원료는 이 원료는 다음의 구조를 갖는 유기화합물이다.; 이명으로는 주어진 정보가 없습니다.(이)가 있습니다; 사용 용도로는 주어진 정보가 없습니다; 주의사항으로는 주어진 정보가 없습니다; 사용 효과로는 주어진 정보가 없습니다;" question "1. 스테아로일메틸글루카마이드스테아레이트의 CAS No는 무엇인가요? 2. 스테아로일메틸글루카마이드스테아레이트의 영문명은 무엇인가요? 3. 스테아로일메틸글루카마이드스테아레이트의 구조는 무엇인가요? 4. 스테아로일메틸글루카마이드스테아레이트의 사용 용도는 무엇인가요? 5. 스테아로일메틸글루카마이드스테아레이트의 사용 효과는 무엇인가요?" ▼ 10097 context "표준명은 스테아로일사코신이고; 영문명은 Stearoyl Sarcosine입니다; 이 성분의 CAS No는 주어진 정보가 없습니다.; 이 원료는 이 원료는 다음의 구조를 갖는 N-메틸글라이신의 N-스테아로일 유도체이다.; 이명으로는 주어진 정보가 없습니다.(이)가 있습니다; 사용 용도로는 주어진 정보가 없습니다; 주의사항으로는 주어진 정보가 없습니다; 사용 효과로는 주어진 정보가 없습니다;" question "1. 스테아로일사코신의 CAS No는 무엇인가요? 2. 이 원료는 어떤 구조를 갖는 N-메틸글라이신의 N-스테아로일 유도체인가요? 3. 이명으로는 어떤 성분이 있나요? 4. 사용 용도로는 어떤 효과가 있나요? 5. 주어진 정보가 없으므로, 어떤 사유로 사용될 수 있나요?"
--	---

활용방안

- Retrieval된 문서의 query와 실제 질문과 Similarity 계산하여 rerank
- Document의 query들을 유사질문으로 추천