

SK네트웍스 Family AI과정 6기

데이터 전처리 학습된 인공지능 모델

□ 개요

- 산출물 단계 : 데이터 전처리
- 평가 산출물 : 학습된 인공지능 모델
- 제출 일자 : 2025.03.09
- 깃허브 경로 : <https://github.com/SKNETWORKS-FAMILY-AICAMP/SKN06-FINAL-3Team>
- 작성 팀원 : 박서윤

사용 데이터 및 기술	context-question data set 1. AI-Hub에서 제공하는 한국어 기반 컨텍스트-질문 쌍 데이터 https://www.aihub.or.kr/aihubdata/data/view.do?currMenu=115&topMenu=100&aihubDataSe=realm&dataSetSn=89 2. huggingface에서 context와 질문을 쌍으로 구성한 한국어 질문-답변 데이터셋 https://huggingface.co/datasets/yuneun92/create_qa_news
상황	1. AIHub에서 제공하는 한국어 기반 컨텍스트-질문 쌍 데이터 - 데이터는 정치 카테고리를 제외한 총 8개 카테고리(경제, 사회, 생활, IT/과학, 연예, 스포츠, 문화, 미용/건강)로 구성 - 각 카테고리에서 동일한 비율로 총 500개를 균등하게 추출 2. huggingface에서 context와 질문을 쌍으로 구성한 한국어 질문-답변 데이터셋 - instruction과 output 형태로 제공되지만, 초기 상태에서 두 필드가 일치하지 않고 뒤섞여 있어 일관성을 높이기 위해 자카드 유사도를 활용한 매핑 작업 수행 1) 각 output에 대해 가장 높은 유사도를 가지는 instruction을 선택 2) 유사도가 0.08 이상인 경우를 유사한 pair로 판단하고, 해당 기준을 만족하는 instruction-output 쌍을 800개 선정 - output 값이 질문 형태가 아닌 경우(?로 끝나지 않는 경우), 해당 데이터가 요약문일 가능성이 높아 제외시킴

